

Clustering

Trịnh Tấn Đạt

Khoa CNTT – Đại Học Sài Gòn

Email: trinhtandat@sgu.edu.vn

Website: <https://sites.google.com/site/ttdat88/>

Nội dung

- Giới thiệu: Clustering
- Phân loại
- Thuật toán Kmeans
- Hierarchical Clustering
- Density-Based Clustering
- Bài tập


Clustering

❖ Học không giám sát (Unsupervised learning)

- Tập học (training data) bao gồm các quan sát, mà mỗi quan sát *không có thông tin về label hoặc giá trị đầu ra mong muốn*.
- Mục đích là tìm ra (học) các cụm, các cấu trúc, các quan hệ tồn tại ẩn trong tập dữ liệu hiện có.


Clustering

- ❖ Phân cụm/Phân nhóm (clustering)
- Phát hiện các nhóm dữ liệu, nhóm tính chất



Clustering

- Ví dụ: Nhận diện phần tử biên (outliers) và giảm thiểu nhiễu (noisy data)




Clustering

- Ví dụ: Phân cụm ảnh




Clustering

- Ví dụ: Community detection
 - Phát hiện các cộng đồng trong mạng xã hội




Clustering

- Ví dụ: Image segmentation



Clustering

- Clustering: là quá trình phân nhóm/cụm dữ liệu/đối tượng vào các nhóm/cụm
 - Các đối tượng trong cùng một nhóm tương tự (tương đồng) với nhau hơn so với đối tượng ở các nhóm khác.



Clustering

- Input: một tập dữ liệu $\{x_1, \dots, x_M\}$ không có nhãn (hoặc giá trị đầu ra mong muốn)
- Output: các cụm (nhóm) của các quan sát
- Một cụm (cluster) là một tập các quan sát
 - Tương tự với nhau (theo một ý nghĩa, đánh giá nào đó)
 - Khác biệt với các quan sát thuộc các cụm khác

Clustering

- Mỗi cụm/nhóm nên có bao nhiêu phần tử?
- Các phần tử nên được phân vào bao nhiêu cụm/nhóm?
- Bao nhiêu cụm/nhóm nên được tạo ra?



Bao nhiêu cụm?



6 cụm?



2 cụm?



4 cụm?


Clustering

- ❖ Các yêu cầu khi thiết kế thuật toán phân cụm dữ liệu:
 - Có thể tương thích, hiệu quả với dữ liệu lớn, số chiều lớn
 - Có khả năng xử lý các dữ liệu khác nhau
 - Có khả năng khám phá các cụm với các dạng bất kỳ
 - Khả năng thích nghi với dữ liệu nhiễu
 - Ít nhạy cảm với thứ tự của các dữ liệu vào
 - Phân cụm ràng buộc
 - Dễ hiểu và dễ sử dụng

Clustering


- ❖ Phân loại các phương pháp clustering
 - Phân hoạch (partitioning): phân hoạch tập dữ liệu n phần tử thành k cụm
 - **Kmeans, Fuzzy C-mean,...**
 - Phân cấp (hierarchical): xây dựng phân cấp các cụm trên cơ sở các đối tượng dữ liệu đang xem xét
 - **AGNES (Agglomerative NESting), DIANA (Divisive ANAlysis) ,...**
 - Dựa trên mật độ (density-based): dựa trên hàm mật độ, số đối tượng lân cận của đối tượng dữ liệu.
 - **DBSCAN, OPTICS, MeanShift ,...**
 - Dựa trên mô hình (model-based): một mô hình giả thuyết được đưa ra cho mỗi cụm; sau đó hiệu chỉnh các thông số để mô hình phù hợp với cụm dữ liệu/đối tượng nhất.
 - **EM, SOMs ,...**
 - Spectral clustering : **phân cụm dựa trên đồ thị**
 - ...

Clustering




Clustering

- Ví dụ: Phân hoạch (partitioning)



Clustering


- Ví dụ: Phân cấp (hierarchical)



Clustering

- Đánh giá chất lượng phân cụm (Clustering quality)
 - Khoảng cách/sự khác biệt *giữa các cụm* → Cần được cực đại hóa
 - Khoảng cách/sự khác biệt *bên trong một cụm* → Cần được cực tiểu hóa

Clustering : Example



Kmeans

- K-means được giới thiệu đầu tiên bởi Lloyd năm 1957
- Là phương pháp phân cụm phổ biến nhất trong các phương pháp dựa trên phân hoạch (partition-based clustering)
- Giải thuật K-means phân chia tập dữ liệu thành k cụm
 - Mỗi cụm (cluster) có một điểm trung tâm/ trọng tâm, được gọi là **centroid**
 - k (tổng số các cụm thu được) là một giá trị được cho trước (vd: được chỉ định bởi người thiết kế hệ thống phân cụm)
 - Một đối tượng được phân vào một cụm nếu khoảng cách từ đối tượng đó đến trọng tâm của cụm đang xét là nhỏ nhất
 - Quá trình lặp đi lặp lại cho đến hàm mục tiêu bé hơn một ngưỡng cho phép hoặc các trọng tâm không đổi


$$E = \sum_{i=1}^k \sum_{p \in C_i} |p - m_i|$$

Kmeans


- Algorithm:
- Input:
 - tập học $D=\{x_1, x_2, \dots, x_r\}$ (x_i là một quan sát - một vector trong một không gian n chiều))
 - số lượng cụm k
 - khoảng cách $d(x, y)$
- Step 1. Chọn ngẫu nhiên k quan sát **để sử dụng làm các điểm trung tâm ban đầu** (*initial centroids*) của k cụm.
- Step 2. Lặp liên tục hai bước sau cho đến khi gặp điều kiện hội tụ (*convergence criterion*):
 - 2.1. Đối với mỗi quan sát, gán nó vào cụm (trong số k cụm) mà có tâm (centroid) gần nó nhất.
 - 2.2. Đối với mỗi cụm, tính toán lại điểm trung tâm của nó dựa trên tất cả các quan sát thuộc vào cụm đó.

Kmeans


- Ví dụ:



(A). Random selection of k centers







Iteration 1: (B). Cluster assignment



(C). Re-compute centroids


Kmeans

- Ví dụ:




Kmeans

- Ví dụ:




Kmeans

- Ví dụ:




Kmeans

- Ví dụ:




Kmeans

- Ví dụ:




Kmeans

- Ví dụ:



Kmeans

- Ví dụ:



Kmeans

❖ *Convergence criterion :*

- Quá trình phân cụm kết thúc, nếu:
 - Không có (hoặc có không đáng kể) việc gán lại các quan sát vào các cụm khác, *hoặc*
 - Không có (hoặc có không đáng kể) thay đổi về các điểm trung tâm (centroids) của các cụm, *hoặc*
 - Giảm không đáng kể về tổng lỗi phân cụm

$$Error = \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} d(\mathbf{x}, \mathbf{m}_i)^2$$

- C_i : Cụm thứ i
- $\mathbf{m}_i$: Điểm trung tâm (centroid) của cụm C_i
- $d(\mathbf{x}, \mathbf{m}_i)$: Khoảng cách (khác biệt) giữa quan sát $\mathbf{x}$ và điểm trung tâm $\mathbf{m}_i$

Kmeans

- Centroids:
- Xác định điểm trung tâm: Điểm trung bình (*Mean centroid*)

$$\mathbf{m}_i = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$$

- (vector) $\mathbf{m}_i$ là điểm trung tâm (centroid) của cụm C_i
- $|C_i|$ kích thước của cụm C_i (tổng số quan sát trong C_i)

Kmeans

- Distance function

khoảng cách *Minkowski*

$$d(i, j) = \sqrt[q]{(|x_{i1} - x_{j1}|^q + |x_{i2} - x_{j2}|^q + \dots + |x_{ip} - x_{jp}|^q)}$$

$i = (x_{i1}, x_{i2}, \dots, x_{ip})$ và $j = (x_{j1}, x_{j2}, \dots, x_{jp})$ là 2 phần tử dữ liệu trong p -dimensional, q là số nguyên dương


nếu $q = 1$, d là khoảng cách Manhattan

nếu $q = 2$, d là khoảng cách Euclid

khoảng cách cosine : $d_{\cos}(i, j) = i^T j / (\|i\| \|j\|)$

Kmeans

- Distance function
 - Mỗi hàm sẽ tương ứng với một cách nh.n về dữ liệu.
 - Chọn hàm nào?
- Có thể thay bằng độ đo tương đồng (similarity measure)



Kmeans


- Pros:
 - Đơn giản: dễ cài đặt, rất dễ hiểu
 - Rất linh động: cho phép dùng nhiều độ đo khoảng cách khác nhau
 - K-means thường phù hợp với các cụm hình cầu
 - được dùng phổ biến nhất
- Cons:
 - Phải xác định số cụm trước
 - Không thể xử lý nhiễu và ngoại lai
 - Phụ thuộc vào việc chọn các điểm trung tâm ban đầu (initial centroids)

Kmeans

- How to choose k?


$$Error = \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} d(\mathbf{x}, \mathbf{m}_i)^2$$

The location of a bend (knee) in the plot is generally considered as an indicator of the appropriate number of clusters.




Kmeans

- Outlier




(A): Undesirable clusters




(B): Ideal clusters

Kmeans


- Initial centroids



(A). Random selection of seeds (centroids)



(B). Iteration 1



(C). Iteration 2


Kmeans

❖ Initial centroids


Kết hợp nhiều kết quả phân cụm với nhau → Kết quả tốt hơn!



(A). Random selection of k seeds (centroids)



(B). Iteration 1



(C). Iteration 2

Kmeans

❖ Initial centroids

- Cải tiến : kmeans ++

- Idea:


- Lựa chọn ngẫu nhiên hạt nhân thứ 1 (m_1)
- Lựa chọn hạt nhân thứ 2 (m_2) càng xa càng tốt so với hạt nhân thứ 1 ...

...

- Lựa chọn hạt nhân thứ i (m_i) càng xa càng tốt so với hạt nhân gần nhất trong số $\{m_1, m_2, \dots, m_{i-1}\}$

Kmeans

- K-means (với khoảng cách Euclid) phù hợp với các cụm hình cầu.
- *K-means không phù hợp để phát hiện các cụm (nhóm) không có dạng hình cầu.*



Kmeans

- Online kmeans
- K-means:
 - Cần dùng toàn bộ dữ liệu tại mỗi bước lặp
 - Do đó không thể làm việc khi dữ liệu quá lớn (big data)
 - Không phù hợp với luồng dữ liệu (stream data, dữ liệu đến liên tục)
- *Online K-means cải thiện nhược điểm của K-means* cho phép ta phân cụm dữ liệu rất lớn, hoặc phân cụm luồng dữ liệu.
 - Online learning
 - Stochastic gradient descent

Online Kmeans based SGD

- Loss function

$$Q(w) = \sum_{i=1}^M \|x_i - w(x_i)\|_2^2$$

Trong đó $w(x_i)$ là tâm gần nhất với x_i .

Khởi tạo K tâm ban đầu.

Cập nhật các tâm mỗi khi một điểm dữ liệu mới đến:

- ▣ *Tại bước t , lấy một quan sát x_t .*
- ▣ *Tìm tâm w_t gần nhất với x_t . Sau đó cập nhật lại w_t như sau:*

$$w_{t+1} = w_t + \gamma_t (x_t - w_t)$$

Hierarchical Clustering

- Idea :

- Xuất phát mỗi cụm có một đối tượng (nếu có n đối tượng thì sẽ có n cụm).
- Tiếp theo, tiến hành gộp các cụm cặp hai đối tượng có **khoảng cách bé nhất**.
- Quá trình ghép cặp tiến hành lặp cho đến khi các cụm được ghép thành một cụm duy nhất.


Hierarchical Clustering

- Phân cụm dữ liệu bằng phân cấp (hierarchical clustering): nhóm các đối tượng vào cây phân cấp của các cụm
 - Agglomerative: bottom-up (trộn các cụm)
 - Divisive: top-down (phân tách các cụm)
- Không yêu cầu thông số nhập k (số cụm)
- Yêu cầu điều kiện dừng
- Không thể quay lui ở mỗi bước trộn/phân tách

Hierarchical Clustering

An agglomerative hierarchical clustering method: AGNES
(Agglomerative NESTing) → bottom-up

A divisive hierarchical clustering method: DIANA (Divisive ANALysis)
→ top-down




Agglomerative and divisive hierarchical clustering on data objects $\{a, b, c, d, e\}$.

Hierarchical Clustering


- AGNES (Agglomerative Nesting)

- Khởi tạo: mỗi đối tượng là một cụm (lá)
- Độ quy trộn các nút có sự khác nhau thấp nhất
- Tiêu chí: min distance, max distance, avg distance, center distance
- Cuối cùng tất cả các nút thuộc về một cụm (gốc)



Hierarchical Clustering

- DIANA (Divisive Analysis)
 - Ngược thứ tự so với AGNES
 - Bắt đầu với cụm gốc chứa tất cả các đối tượng
 - Thực hiện Đệ quy chia thành các cụm nhỏ
 - Cuối cùng, mỗi cụm chứa một đối tượng duy nhất



Hierarchical Clustering

- ❖ Khoảng cách giữa hai cụm có thể là một trong các loại sau:
- Single-linkage clustering :khoảng cách giữa hai cụm là *khoảng cách ngắn nhất giữa hai đối tượng của hai cụm*.


$$D(C_1, C_2) = \min_{x_1 \in C_1, x_2 \in C_2} D(x_1, x_2)$$



Hierarchical Clustering

- Complete-linkage clustering: khoảng cách giữa hai cụm là *khoảng cách lớn nhất giữa hai đối tượng của hai cụm*.


$$D(C_1, C_2) = \max_{x_1 \in C_1, x_2 \in C_2} D(x_1, x_2)$$




Hierarchical Clustering

- Average-linkage clustering: khoảng cách giữa hai cụm là *khoảng cách trung bình giữa hai đối tượng của hai cụm*

$$D(C_1, C_2) = \frac{1}{|C_1|} \frac{1}{|C_2|} \sum_{x_1 \in C_1} \sum_{x_2 \in C_2} D(x_1, x_2)$$




Hierarchical Clustering



Hierarchical Clustering


- Ví dụ:

- Quá trình Phân cụm bằng phân cấp được biểu diễn bởi cấu trúc cây (dendrogram).



Hierarchical Clustering

Clustering behavior




Complete link gives preference to **compact/spherical** clusters (i.e., clusters having consistent length). **Single link** can produce **long stretched** clusters ($A \rightarrow B \rightarrow C \rightarrow D \dots$)

Density-Based Clustering

- Phân cụm dữ liệu dựa trên mật độ
 - Mỗi cụm là một vùng dày đặc (dense region) gồm các đối tượng.
 - Các đối tượng trong vùng thưa hơn được xem là nhiễu.
 - Mỗi cụm có dạng tùy ý.
- Giải thuật
- DBSCAN (Density-Based Spatial Clustering of Applications with Noise)
- OPTICS (Ordering Points To Identify the Clustering Structure)
- DENCLUE (DENsity-based CLUstEring)
- MeanShift

Density-Based Clustering



Density reachability and density connectivity in density-based clustering

Density-Based Clustering


- Idea of MeanShift

- Iterative Mode Search


1. Initialize random seed, and window W
2. Calculate center of gravity (the “mean”) of W :
3. Shift the search window to the mean
4. Repeat Step 2 until convergence

$$\sum_{x \in W} x H(x)$$


MeanShift




MeanShift




MeanShift




MeanShift




MeanShift



MeanShift




MeanShift



MeanShift

- MeanShift không cần chọn trước số nhóm cần phân loại. Thuật toán có thể tìm được số nhóm vì chúng sẽ dịch chuyển tự động.
- Vấn đề trong MeanShift là chọn window - bán kính vùng quét để tính mean - là bao nhiêu




Tìm hiểu thêm

- Subspace Clustering



Bài Tập

1) Toy Example: Tạo ngẫu nhiên 3 loại dữ liệu như sau


- Three Data: X_1 , X_2 , X_3
 - X_1 : 2 clusters
 - X_2 : 2 clusters
 - X_3 : 1 cluster + outlier
- Cài đặt và so sánh hiệu quả của
 - Kmean
 - DBSCAN




Toy Example



Toy Example



Toy Example



Bài Tập

2) Color Clustering based Kmeans


- Imagine you have an image with millions of colors.
- In most images, a large number of the colors will be unused, and many of the pixels in the image will have similar or even identical colors



<https://jakevdp.github.io/PythonDataScienceHandbook/05.11-k-means.html>

<https://towardsdatascience.com/introduction-to-image-segmentation-with-k-means-clustering-83fdoage2fc3>

Dominant Color



<https://buzzrobot.com/dominant-colors-in-an-image-using-k-means-clustering-3c7af4622036>